

Raccomandare opere d'arte nel cultural heritage

TF-IDF contro CLIP su dati MET Open Access, con profili utente
sintetici

Massimiliano Giangreco · Matricola 561883

Prof. Giuseppe Sansonetti · Settembre 2026



Il problema

1

Information overload

Il MET espone centinaia di migliaia di opere: nessun visitatore può esplorarle tutte.

2

Nessuna interazione

Il museo pubblica metadati e immagini, non rating né visite: il collaborative filtering non ha input.

3

Approccio content-based

Si raccomandano opere vicine alle preferenze dichiarate, usando solo i contenuti delle opere.

Quale rappresentazione dei contenuti funziona meglio: lessicale (TF-IDF) o semantica (CLIP)?

Cinque domande di ricerca

RQ1

Il TF-IDF supera le baseline banali (random, popolarità)?

RQ2

Quanta parte del risultato dipende dal termine periodo, condiviso con il ground truth?

RQ3

CLIP è competitivo con il TF-IDF? Il segnale viene dal testo o dall'immagine?

RQ4

I risultati sono robusti rispetto ad α , k e al campione di utenti?

RQ5

Cosa si può spiegare del comportamento dei modelli, e dove falliscono?

Due modelli a confronto

TF-IDF • lessicale

- Token di metadati: nazionalità, classificazione, tag
- $\text{Peso} = \text{conteggio} \times \text{IDF smussato}$
- Similarità coseno profilo-opera
- Spiegabile: il coseno si scompone per token

vs

CLIP • semantico

- ViT-B/32, embedding a 512 dimensioni
- Il prompt utente è confrontato con testo e immagine
- α mescola immagine (1) e testo (0)
- Lega concetti affini senza parole in comune

Punteggio finale: $(1 - w) \cdot \text{similarità} + w \cdot \text{boost periodo}$, con $w = 0.15$

Dati e profili sintetici

2000

dipinti European Paintings

34

nazionalità degli artisti

527


tag distinti

50

profili utente sintetici

Rilevanti: il top 5% per affinità, cioè 100 opere per utente.

Pesi dei criteri nel ground truth



Circolarità: ground truth e modelli condividono il termine periodo.

Pipeline e protocollo




Risultato principale: TF-IDF supera CLIP

0.588


Precision@10 del TF-IDF, contro 0.302 di CLIP (seed 42).

- Circa 12 volte il caso (random 0.049)
- Su 10 seed: 0.555 contro 0.278
- Popolarità vicina al caso (0.061 e 0.040)



Barre d'errore: errore standard approssimato (std tra utenti / $\sqrt{50}$). * α scelto post hoc sugli stessi utenti.

Il periodo è un confondente



Solo periodo: 0.354

Circa 7 volte il caso, senza alcun contenuto.


Vantaggio non dimostrato

+0.078, IC $[-0.012, +0.170]$, $p = 0.134$.

Quindi

0.432 è il numero più difendibile per il contenuto.

Test di significatività appaiati



† confronti esplorativi: $\alpha=0.2$ scelto post hoc sugli stessi 50 utenti. Wilcoxon signed-rank appaiato, 10.000 resample bootstrap.


Significativi

TF-IDF supera CLIP, con e senza periodo. Il TF-IDF con periodo supera il solo periodo.

Non dimostrati

Testo contro immagine in CLIP. TF-IDF senza periodo contro solo periodo.

Testo, immagine e scelta di α




Testo o immagine?

+0.062 ($p = 0.106$) con periodo, +0.008 ($p = 0.732$) senza: non distinguibili.


$\alpha = 0.2$

Vantaggio su $\alpha = 0.5$ da +0.044 in campione a circa +0.011 fuori campione.

Robustezza: seed e k




TF-IDF sopra CLIP in 10 seed su 10, con media 0.555 contro 0.278.



A ogni k l'ordine TF-IDF > {periodo, CLIP} è stabile. Tra periodo e CLIP dipende da k.

Spiegabilità: il gap sulla nazionalità

Top-1 TF-IDF con almeno un token in comune col profilo



Scomposizione esatta

Il coseno TF-IDF si scompone per token e per categoria.

Nazionalità contro tag

64% contro 96%, McNemar $p = 0.0008$.

CLIP

Leave-one-out per preferenza: un proxy, non una scomposizione.

Conclusioni e limiti

Cosa abbiamo trovato

- TF-IDF supera CLIP in modo robusto, ma il risultato è atteso: il ground truth è costruito sui metadati
- Il periodo è un confondente quantificato, non eliminato
- Testo e immagine in CLIP non sono distinguibili con 50 utenti

Limiti e prossimi passi

- Profili sintetici, 2000 dipinti, un solo modello CLIP
- Nazionalità nel testo CLIP e prompt per preferenza
- Ibrido TF-IDF + CLIP, metriche beyond-accuracy, studio con utenti reali

Osservato non significa dimostrato: è la chiave di lettura di tutto il lavoro.

Codice e risultati

<https://github.com/ilMassy/cultural-heritage-recommender>

src/

Codice dei recommender, metriche, ablation, test statistici e spiegabilità, con 58 test unitari.

results/

Metriche, raccomandazioni, test di significatività e spiegazioni: da qui vengono tutti i numeri del report.

Report completo

Metodo, risultati e analisi critica nel file Report_Finale_SII.pdf; le immagini sono in figures/.

Grazie per l'attenzione

Massimiliano Giangreco · Matricola 561883

Prof. Giuseppe Sansonetti · Settembre 2026