



Raccomandazione di Opere d'Arte per il Cultural Heritage

TF-IDF contro CLIP su dati MET Open Access: un confronto sperimentale con profili utente sintetici

Python 3.12 · PyTorch 2.14 · Transformers 5.17 · Dataset MET Open Access (CC0) · 58 unit test superati

Autore	Massimiliano Giangreco
Matricola	561883
Corso di laurea	Laurea Magistrale in Ingegneria Informatica
Insegnamento	Sistemi Intelligenti per Internet (SII)
Docente	Prof. Giuseppe Sansonetti
Ateneo	Università degli Studi Roma Tre
Data	Settembre 2026
Repository	https://github.com/ilMassy/cultural-heritage-recommender

Abstract

Un museo con migliaia di opere pone un classico problema di *information overload*: come mostrare a ciascun visitatore le opere più affini ai suoi interessi? Questo lavoro confronta due paradigmi **content-based** per raccomandare dipinti del Metropolitan Museum of Art (2000 opere del dipartimento *European Paintings*): un recommender **TF-IDF + similarità coseno** sui metadati testuali e un recommender in spazio **CLIP** (`openai/clip-vit-base-patch32`) che usa il testo delle opere, le loro immagini o una combinazione dei due.

Poiché il MET non fornisce interazioni utente, la valutazione usa **50 profili sintetici** con un ground truth costruito dai metadati (top 5% per affinità, 100 opere rilevanti per utente). Il progetto pone al centro il rigore metodologico: baseline banali (random, popolarità), ablation sul termine temporale condiviso col ground truth, ablation su α , k e su 10 seed di profili, test di significatività appaiati (Wilcoxon + bootstrap) e un modulo di spiegabilità.

Risultato principale. Il TF-IDF supera CLIP in modo statisticamente supportato (Precision@10 0.588 contro 0.302 a seed 42; 0.555 contro 0.278 in media su 10 seed; TF-IDF sopra in 10 seed su 10). Il risultato va però letto con cautela: il ground truth condivide con i recommender il termine "periodo", che da solo ottiene 0.354, e il vantaggio del *solo contenuto* testuale del TF-IDF su tale ranking (0.432 contro 0.354) **non è statisticamente dimostrato** ($p = 0.134$). Testo e immagine in CLIP non sono distinguibili con questo campione.

Parole chiave: sistemi di raccomandazione, content-based, TF-IDF, CLIP, cultural heritage, profili sintetici, valutazione offline, test di significatività.

In sintesi

DA RICORDARE

Cinque risultati, con il loro grado di evidenza

1. **Tutti i modelli personalizzati superano nettamente il caso** (random 0.049), mentre le baseline di popolarità restano vicine ad esso (0.061 e 0.040): la personalizzazione porta segnale, la popolarità no.
2. **TF-IDF > CLIP** con e senza il termine periodo ($p < 0.0001$ a seed 42; con il periodo attivo il TF-IDF è sopra in 10 seed su 10).
3. **Il periodo è un confondente**: da solo dà 0.354; il TF-IDF senza periodo lo supera di +0.078 ma la differenza *non è significativa* (IC 95% [-0.012, +0.170], $p = 0.134$).
4. **Testo e immagine in CLIP non si distinguono** ($p = 0.106$ con periodo, $p = 0.732$ senza).
5. **L' α "migliore" (0.2) è in parte un artefatto di selezione**: fuori campione il vantaggio su $\alpha = 0.5$ scende da +0.044 a circa +0.011.

Sommario

1. Introduzione e obiettivi
 2. Background teorico
 3. Dati, profili sintetici e ground truth
 4. Modelli
 5. Framework software e riproducibilità
 6. Protocollo sperimentale
 7. Risultati
 8. Spiegabilità
 9. Analisi critica e minacce alla validità
 10. Sviluppi futuri
 11. Conclusioni
 12. Bibliografia
- Appendice A: provenienza dei numeri

1. Introduzione e obiettivi

1.1 Contesto

I musei digitalizzano cataloghi con decine di migliaia di opere. Il MET rende disponibili metadati e immagini di centinaia di migliaia di opere con licenza CCO tramite le *Open Access API*. Un sistema di raccomandazione può aiutare il visitatore online a scoprire opere affini ai suoi gusti, comprese quelle poco note: nel campione usato solo

92 opere su 2000 sono contrassegnate come *highlight* (un proxy imperfetto della popolarità), quindi la maggior parte del catalogo appartiene alla cosiddetta **coda lunga** (§2.5). La raccomandazione nel patrimonio culturale è un'area di ricerca consolidata: un esempio è il recommender ibrido che combina attività sui social media e *Linked Open Data* proposto da Sansonetti et al. [24]; qui si lavora invece sui soli contenuti delle opere.

Il contesto ha una caratteristica che orienta tutte le scelte: **non esistono interazioni utente-opera** (rating, click, visite). Il paradigma di riferimento della raccomandazione, il *collaborative filtering*, richiede una matrice di rating e non è quindi applicabile; si ricorre a metodi **content-based** che sfruttano solo le caratteristiche delle opere (§2.1).

1.2 Domande di ricerca

#	Domanda
RQ1	Un recommender content-based classico (TF-IDF + coseno) supera baseline banali come random e popolarità?
RQ2	Quanta parte del risultato dipende dal termine <i>periodo</i> , identico nella formula del ground truth e nei recommender?
RQ3	Un modello multimodale (CLIP) è competitivo con il TF-IDF, e il segnale proviene dal testo o dall'immagine?
RQ4	I risultati sono robusti rispetto a α (mix testo/immagine), k e al campione di utenti (seed)?
RQ5	Cosa si può spiegare del comportamento dei modelli, e dove falliscono?

1.3 Contributi

- Una **pipeline riproducibile** (dati $\rightarrow$ profili $\rightarrow$ ground truth $\rightarrow$ 4 famiglie di modelli $\rightarrow$ metriche $\rightarrow$ test statistici) con 58 test unitari sul codice di valutazione.
- Un **confronto controllato** TF-IDF/CLIP con ablation che isolano il termine temporale, separano testo e immagine e verificano la stabilità rispetto a α , k e seed.
- Una **distinzione esplicita tra risultati osservati e risultati dimostrati**, con 11 test appaiati e la correzione di ipotesi iniziali non confermate (§9.1).
- Un **modulo di spiegabilità** che scompone esattamente il coseno TF-IDF per token e ha rivelato un gap di personalizzazione sulla nazionalità (§8).

2. Background teorico

2.1 Sistemi di raccomandazione e paradigmi

Un sistema di raccomandazione (RS) riduce l'*information overload* stimando la rilevanza degli item per un utente e proponendo una lista ordinata (top-N). I paradigmi principali [2]:

Paradigma	Input necessario	Punti di forza	Limiti tipici
Collaborative filtering (CF)	matrice utente-item di rating (espliciti o impliciti)	nessuna conoscenza sugli item; serendipità	<i>cold-start</i> , sparsità, scalabilità
Content-based	descrizione degli item + profilo utente	funziona per item nuovi; spiegabile	sovra-specializzazione; richiede buoni metadati

Paradigma	Input necessario	Punti di forza	Limiti tipici
Knowledge-based	conoscenza di dominio e requisiti espliciti	adatto a acquisti occasionali	costo di <i>knowledge engineering</i>
Ibridi	combinazione dei precedenti	mitigano i limiti dei singoli	maggiore complessità

CF user-based [6]: dato l'utente attivo a , si trovano i vicini b più simili (tipicamente con il coefficiente di Pearson, che corregge per la diversa scala di rating degli utenti) e si predice

$$\text{pred}(a, p) = \bar{r}_a + \frac{\sum_{b \in N} \text{sim}(a, b) (r_{b,p} - \bar{r}_b)}{\sum_{b \in N} \text{sim}(a, b)}$$

CF item-based [7, 8]: la predizione usa la similarità tra item (coseno, o *adjusted cosine* che sottrae la media dell'utente):

$$P(u, p) = \frac{\sum_{i \in N(p)} \text{sim}(i, p) r_{u,i}}{\sum_{i \in N(p)} \text{sim}(i, p)}$$

La similarità tra item è più stabile nel tempo di quella tra utenti e può essere precalcolata offline: è la ragione per cui l'approccio item-to-item scala a cataloghi di milioni di elementi, come ad Amazon [8].

Perché il CF non è applicabile qui. Il MET pubblica metadati e immagini, non log di fruizione. Con una matrice di rating vuota, il CF non ha input. Questo motiva sia la scelta content-based sia la costruzione di **profili sintetici** (§3.2). Se un museo disponesse di log di visita, un CF item-based o un ibrido sarebbe il naturale passo successivo (§10).

2.2 Content-based, Vector Space Model e TF-IDF

Nel *Vector Space Model* [4] item e profilo sono vettori di pesi su un vocabolario di termini. Il peso TF-IDF [5] combina la frequenza del termine nell'item con la sua rarità nella collezione, in una forma tipica

$$w_{t,d} = \log(f_{t,d} + 1) \cdot \log \frac{N}{\text{df}_t}$$

dove $f_{t,d}$ è la frequenza di t in d , N il numero di item e df_t il numero di item che contengono t . Termini rari (alto IDF) discriminano di più. La rilevanza di d per il profilo q è il coseno

$$\cos(q, d) = \frac{q \cdot d}{\|q\| \|d\|}$$

Variante implementata (`src/recommender_baseline.py`, scritta da zero in Python/NumPy con vettori sparsi, senza `scikit-learn`):

$$w_{t,d} = f_{t,d} \cdot \left(\ln \frac{N}{1 + \text{df}_t} + 1 \right)$$

- **TF grezzo** (conteggio, senza logaritmo né normalizzazione per lunghezza): i documenti sono brevi e i token compaiono di norma una sola volta, quindi nella pratica il peso coincide con l'IDF.
- **IDF smussato** con logaritmo naturale, calcolato sulle $N = 2000$ opere. Il termine $+1$ al denominatore e quello additivo finale mantengono il peso positivo anche per i token presenti in quasi tutto il catalogo.
- **Profilo utente come documento**: i token delle sue preferenze dichiarate sono vettorizzati con lo stesso IDF del catalogo (nessun IDF proprio del profilo). L'unica normalizzazione è quella del coseno (norma L2).

Nel progetto i termini sono **token di metadati con prefisso di categoria** (`nat::`, `cls::`, `tag::`), che permettono di attribuire il punteggio alle singole dimensioni (§8).

Limite classico: il *vocabulary mismatch*. Due descrizioni dello stesso concetto con parole diverse non hanno termini in comune, e il coseno lessicale le vede come non correlate. Rimedi noti [3]: normalizzazione (stemming), espansione della query o dei tag, e rappresentazioni semantiche. È il motivo per cui si confronta il TF-IDF con un modello di embedding.

2.3 CLIP: embedding multimodali

CLIP [1] addestra due encoder (testo e immagine) con apprendimento contrastivo su coppie immagine–didascalia, portando testo e immagine corrispondenti vicini in un unico spazio. Con N coppie in un batch, e s_{ij} la similarità coseno tra immagine i e testo j , la perdita simmetrica è

$$\mathcal{L} = -\frac{1}{2N} \sum_{i=1}^N \left[\log \frac{e^{s_{ii}/\tau}}{\sum_j e^{s_{ij}/\tau}} + \log \frac{e^{s_{ii}/\tau}}{\sum_j e^{s_{ji}/\tau}} \right]$$

Il modello usato è `openai/clip-vit-base-patch32`: embedding a **512 dimensioni**, L2-normalizzati, contesto testuale di **77 token**. Poiché testo e immagine condividono lo spazio, lo stesso prompt utente si confronta sia con il testo sia con l'immagine di ogni opera: da qui la variabile α del §4.3. Diversamente dal TF-IDF, CLIP è in grado di legare concetti semanticamente vicini anche senza sovrapposizione lessicale.

2.4 Tag, folksonomie e metadati

I **tag utente** [14] sono etichette libere assegnate dagli utenti agli item e formano una *folksonomia*, a differenza delle tassonomie controllate. Xu et al. li classificano in *content-based*, *context-based*, *attribute*, *subjective* e *organizational*. Le criticità note sono rumore, errori, spam, sparsità e *vocabulary mismatch*; per gli item non taggati esistono tecniche di individuazione automatica dei tag (pesi TF-IDF, classificazione, MMR [23] per evitare tag ridondanti).

I tag del MET sono un caso diverso: sono un **vocabolario assegnato dall'istituzione**, non una folksonomia di utenti (in media 3.17 tag per opera; 99.7% delle opere ne ha almeno uno), e descrivono soprattutto il contenuto raffigurato (*Men, Portraits, Dogs, Madonna and Child*). Sono il segnale testuale principale sia del recommender sia del ground truth (peso 0.40).

2.5 Cold-start e coda lunga

Il **cold-start** [10] si presenta per nuovi utenti, nuovi item o interi nuovi sistemi. I RS content-based lo affrontano meglio del CF per i nuovi item, purché siano descritti da metadati. Nel nostro scenario il profilo dichiarato dell'utente (nazionalità, periodo, tag, classificazione) sostituisce lo storico: è un rimedio classico al *new-user cold-start* (elicitazione esplicita delle preferenze). Il caso duale, **opere con metadati mancanti**, è dove ci si aspetta che gli embedding visivi di CLIP portino valore, ed è una proposta futura (§10).

Il modello di mercato della **coda lunga** [9] sostiene che l'insieme dei prodotti di nicchia può pesare quanto (o più) degli hit, se gli utenti dispongono di strumenti per trovarli: i RS sono quello strumento. La baseline "popolarità/highlight" del §4.1 rappresenta esattamente l'alternativa priva di personalizzazione che ignora la coda.

2.6 Valutazione offline

Si distingue la valutazione dell'**accuratezza delle predizioni** (MAE, RMSE, per compiti di rating prediction) da quella dell'**accuratezza di ranking** su liste top-N [11, 12]. Il nostro compito è di ranking: ciascun modello produce, per ogni utente, una lista di k opere, confrontata con un insieme di opere rilevanti R_u .

$$P@k = \frac{|\text{top}_k \cap R_u|}{k}, \quad R@k = \frac{|\text{top}_k \cap R_u|}{|R_u|}$$
$$DCG@k = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i+1)}, \quad NDCG@k = \frac{DCG@k}{IDCG@k}$$

Il DCG [13] assume che gli item rilevanti siano tanto più utili quanto più in alto compaiono; l'IDCG è il DCG del ranking ideale, che porta NDCG in $[0, 1]$. Nel progetto il gain è **binario**.

NOTA

Tetto teorico della recall. Con $|R_u| = 100$ e $k = 10$, $R@10 \leq k/|R_u| = 0.10$, e $R@10 = P@10/10$: la recall *normalizzata* ($R/0.10$) coincide con la precision. Per questo nel testo si riporta soprattutto P@10 (le altre metriche sono nelle tabelle).

Le metriche *beyond accuracy* (copertura, novità, serendipità, diversità) sono rilevanti per la coda lunga ma **non sono misurate** in questo lavoro (§9.3, §10).

2.7 Test statistici

Le medie su 50 utenti nascondono una forte variabilità tra utenti (deviazione standard ≈ 0.24). Si confrontano quindi i modelli **utente per utente** con il **test dei ranghi con segno di Wilcoxon** [15], non parametrico e appaiato, e con un **intervallo di confidenza bootstrap** [16] (test appaiati e bootstrap sono tra le scelte comunemente raccomandate per la valutazione di sistemi di retrieval [26]) sulla differenza media (10.000 ricampionamenti degli utenti). Per proporzioni appaiate si usa il **test di McNemar** [17]. Con più confronti aumenta il rischio di falsi positivi: si riporta la soglia di Bonferroni [27] come riferimento (§7.5).

3. Dati, profili sintetici e ground truth

3.1 Dataset

Voce	Valore
Fonte	MET Museum Open Access API (CC0, nessuna chiave) [18]
Dipartimento	11, <i>European Paintings</i> (2645 oggetti; 2000 scaricati con <code>primaryImage</code> e <code>isPublicDomain</code>)
Anni	1200–1920 (<code>objectBeginDate</code> , popolato al 100%)
Qualità	nessun duplicato; <code>artistDisplayName</code> mancante in 1 opera; <code>objectDate</code> mancante nel 23.7% (non usato); 92 opere <code>isHighlight</code>
Classificazione	sbilanciata: ~85% <i>Paintings</i> , ~11% <i>Miniatures</i> , 6 classi in totale
Vocabolari	34 nazionalità, 6 classificazioni, 527 tag distinti

Voce	Valore
Nazionalità più frequenti	French 643, Italian 448, Dutch 227, British 166

ATTENZIONE

Scoperta metodologica. I campi `culture` e `period` risultano **vuoti al 100%** per questo dipartimento (sono popolati per altri, come Arte Egizia o Asiatica). Il progetto originario prevedeva profili su questi campi; sono stati riprogettati su nazionalità dell'artista, fascia temporale (da `objectBeginDate`), classificazione e tag.

Il campione è composto dalle opere con immagine pubblica: non è quindi un campione casuale dell'intero dipartimento (§9.3).

3.2 Profili utente sintetici

Ogni utente ha un **nucleo di preferenze** più rumore controllato:

Dimensione	Contenuto del profilo	Peso base
Nazionalità	1-2 nazionalità dell'artista	0.25
Periodo	centro di una fascia di ± 50 anni	0.20
Classificazione	1-2 classificazioni	0.15
Tag	3-5 tag	0.40

I pesi sono perturbati per utente ($\sigma = 0.05$, minimo 0.02) e rinormalizzati; le preferenze sono campionate proporzionalmente alla frequenza nel catalogo (bias di popolarità realistico). Sono stati scartati profili "netti" (irrealistici) e "sfumati puri" (senza ground truth chiaro).

Diversità effettiva (50 utenti): 14 nazionalità su 34 (French 21, Italian 13, Netherlandish 7, British 6, German 5); 4 classificazioni su 6; 105 tag su 527 (*Men* 19, *Portraits* 18, *Women* 16). Pesi medi effettivi: nazionalità 0.253, periodo 0.202, classificazione 0.135, tag 0.409.

3.3 Ground truth

$$\text{score}(u, i) = w_{\text{nat}} \text{nat} + w_{\text{per}} \text{per} + w_{\text{cls}} \text{cls} + w_{\text{tag}} \text{tag} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.03)$$


con punteggio limitato a $[0, 1]$ e $\text{per} = \max(0, 1 - |\text{anno} - \text{centro}|/50)$. **Le opere rilevanti sono il top 5% per utente: 100 opere.** Seed 42.

In media 381 opere su 2000 (19%) cadono entro ± 50 anni dal centro temporale di un utente (min 51, max 566): il periodo è poco selettivo da solo, ma pesa in modo continuo sul punteggio.

CAUTELA

Circolarità. Il ground truth è una funzione dei metadati. I recommender non riusano mai la formula del ground truth, ma condividono con essa le stesse dimensioni e, soprattutto, il termine periodo. Tutte le conclusioni vanno lette in quest'ottica (§9).

4. Modelli



4.1 Baseline

Modello	Descrizione
Random	lista casuale; media su 200 run (seed 42)
Popolarità (highlight)	raccomanda opere contrassegnate <code>isHighlight</code> ; media su 200 run (std tra run 0.0096)
Popolarità (tag)	raccomanda le opere con i tag più frequenti (stessa lista per tutti)
Solo periodo	ranking per il solo <code>period_boost</code> ($w = 1$): non è un algoritmo interessante, è la funzione condivisa con l'etichettatura, usata come riga di controllo

4.2 TF-IDF + periodo

$$\text{score}(u, i) = (1 - w) \cdot \cos(q_u, d_i) + w \cdot \text{period_boost}(u, i), \quad w = 0.15$$

con `period_boost` della stessa forma del termine periodo del ground truth (0.5 se l'anno è ignoto: ramo di fatto inattivo perché `objectBeginDate` è popolato al 100%). Con $w = 0$ si ottiene il solo contenuto testuale; con $w = 1$ il solo periodo.

4.3 CLIP

Il prompt utente è costruito dalle preferenze dichiarate, con classificazioni, nazionalità e tag; **il periodo non entra nel prompt**. Esempio (utente 0): *"paintings and pastels & oil sketches on paper by German artists, depicting Saint Peter, Flowers, Men, Venice"*.

Il testo dell'opera (`item_text`) è `titolo`, `by <artista>`, `classificazione`, `tag...`, troncato a 77 token, e **non include la nazionalità** (solo il nome dell'artista). Con q l'embedding normalizzato del prompt:

$$s_{\text{img}} = \min \max_u (q \cdot E_{\text{img}}), \quad s_{\text{txt}} = \min \max_u (q \cdot E_{\text{txt}})$$

$$\text{score} = (1 - w_p) [\alpha s_{\text{img}} + (1 - \alpha) s_{\text{txt}}] + w_p \cdot \text{period_boost}$$

- $\alpha = 0$: solo testo; $\alpha = 1$: solo immagine; $0 < \alpha < 1$: mista.
- Il **min-max per utente** sul catalogo è necessario perché i coseni CLIP sono compressi (similarità media immagine-immagine ≈ 0.64).
- $w_p = 0.15$ per default; $w_p = 0$ isola CLIP dal periodo, $w_p = 1$ riproduce il solo periodo (controllo incrociato, §7.2).

5. Framework software e riproducibilità

5.1 Stack

Componente	Uso
Python 3.12	linguaggio
PyTorch 2.14.0 + Transformers 5.17.0	modello CLIP e sue proiezioni [19, 20]
NumPy 2.5.3, SciPy 1.18.1	calcolo numerico; <code>scipy.stats.wilcoxon</code> [21, 22]
pandas, scikit-learn	dipendenze dichiarate in <code>requirements.txt</code>
requests	download dal MET
Pillow, ftfy, tqdm	immagini, pulizia del testo, avanzamento
pytest 9.1.1	test unitari

Esecuzione su laptop Ubuntu con GPU NVIDIA (CUDA) per gli embedding CLIP; i test statistici e i recommender basati su embedding già calcolati non richiedono GPU. Con questa versione di `transformers`, `get_text_features` restituisce un oggetto e non un tensore: `embed_clip.py` usa quindi `text_model / vision_model` più proiezione.

Trasparenza su codice e strumenti. Il progetto usa librerie open source e dati CCO. Parte del codice (script di valutazione, ablation, spiegabilità, test) e dell'analisi critica è stata sviluppata con l'assistenza di Claude (Anthropic). Tutti gli script sono stati eseguiti dall'autore sul dataset reale e i risultati riportati provengono dai file in `results/`.

5.2 Struttura del repository

```
cultural-heritage-recommender/  
├─ src/  
│   ├── fetch_data.py           # download metadati MET  
│   ├── generate_user_profiles.py # profili sintetici + ground truth  
│   ├── recommender_baseline.py  # TF-IDF + coseno  
│   ├── random_baseline.py       # random, popolarità highlight/tag  
│   ├── embed_clip.py            # embedding CLIP testo + immagini (cache)  
│   ├── recommender_clip.py      # recommender in spazio CLIP  
│   ├── metrics.py               # P@k, R@k, NDCG@k condivise  
│   ├── significance_test.py     # Wilcoxon + bootstrap (11 confronti)  
│   ├── ablation_study.py        # k-sweep e seed-sweep  
│   ├── explain.py               # spiegabilità  
│   └─ test_*.py                 # 5 + 58 test  
├─ data/                         # met_objects.jsonl, synthetic_users.json  
├─ results/                      # metriche, raccomandazioni, test, spiegazioni  
├─ requirements.txt / requirements-lock.txt  
└─ README.md
```

`data/clip_cache/` (embedding) non è versionata: è rigenerabile con `embed_clip.py`.

5.3 Come riprodurre

```
python -m venv venv && source venv/bin/activate
pip install -r requirements.txt

python src/fetch_data.py --department_id 11 --max_items 2000 --output data/met_objects.jsonl
python src/generate_user_profiles.py --n_users 50 --stats # seed 42, top 5%
python src/recommender_baseline.py --top_k 10
python src/random_baseline.py --top_k 10 --n_runs 200 --seed 42
python src/embed_clip.py # ViT-B/32, GPU
python src/recommender_clip.py --top_k 10 #  $\alpha \in \{0, 0.5, 1\}$ ,  $w_p = 0.15$ 

python src/significance_test.py # 11 confronti
python src/ablation_study.py --k_sweep --output results/ablation_k.json
python src/ablation_study.py --seed_sweep --seed_sweep_clip --n_seeds 10 --output results/ablation_seed_clip.json
pytest src/test_metrics.py src/test_recommender_clip_scoring.py src/test_random_baseline.py -v
```

Parametri fissati: `seed=42`, `n_users=50`, `top_k=10`, `relevance_top_pct=5%`. I comandi per ciascuna ablation sono nell'Appendice A.

5.4 Validazione del codice

- **58 test unitari** su metriche, punteggio CLIP e baseline casuali (21 + 18 + 19), più 5 test di pipeline su un mini-dataset sintetico: tutti superati.
- Le metriche erano duplicate in due script e differivano in un dettaglio (precision divisa per `k` o per `len(top)`); ora vivono in `src/metrics.py`. L'equivalenza numerica è stata verificata su 2000 casi casuali (0 discrepanze) e la non-regressione confermata sui dati reali.
- **Controllo incrociato**: il ranking "solo periodo" calcolato da `recommender_baseline.py` e da `recommender_clip.py` dà le stesse cifre (0.354 / 0.343).
- **Non coperti da test automatici**: `embed_clip.py` e il caricamento del modello (richiedono GPU e pesi): verificati solo eseguendoli.

6. Protocollo sperimentale

Elemento	Scelta
Utenti / ground truth	50 profili, top 5% per affinità = 100 rilevanti per utente
Metriche principali	P@10, R@10 (con tetto 0.10), NDCG@10 (gain binario)
Confronto tra modelli	test appaiati sugli utenti: Wilcoxon + IC bootstrap 95% (10.000 resample, seed 42)
Ablation sul periodo	$w \in \{0, 0.15, 1\}$ per TF-IDF; $w_p \in \{0, 0.15, 1\}$ per CLIP

Elemento	Scelta
Ablation testo/immagine	$\alpha \in \{0, 0.5, 1\}$ con e senza periodo; sweep fine $\alpha \in \{0, 0.1, \dots, 1\}$
Ablation su k	$k \in \{5, 10, 20, 50\}$, stesso ranking per ciascun modello
Robustezza al campione	10 seed di generazione dei profili (100–109), non usati per scegliere gli iperparametri
Selezione post hoc	$\alpha = 0.2$ scelto sugli stessi 50 utenti; verificato fuori campione sui 10 seed


L'ordine logico è: baseline → confondente (periodo) → confronto tra modelli → robustezza → spiegazione. Ogni affermazione del §11 è ancorata a uno di questi passi.

7. Risultati

7.1 Tabella principale (k = 10, 50 utenti, seed 42)

#	Modello	P@10	R norm.	NDCG@10
1	Random (200 run)	0.049	0.05	0.050
2	Popolarità (highlight)	0.061	0.06	0.061
3	Popolarità (tag)	0.040	0.04	0.035
4	TF-IDF, senza periodo ($w = 0$)	0.432	0.43	0.451
5	TF-IDF + periodo ($w = 0.15$)	0.588	0.59	0.613
6	Solo periodo ($w = 1$)	0.354	0.35	0.343
7	CLIP puro, mista ($w_p = 0, \alpha=0.5$)	0.164	0.16	0.174
8	CLIP + periodo, mista ($w_p = 0.15, \alpha=0.5$)	0.302	0.30	0.315
9	CLIP + periodo, solo testo ($\alpha=0$)	0.314	0.31	0.344
10	CLIP + periodo, solo immagine ($\alpha=1$)	0.252	0.25	0.260
11	CLIP puro, solo testo ($w_p = 0$)	0.158	0.16	0.173
12	CLIP puro, solo immagine ($w_p = 0$)	0.150	0.15	0.150
13	CLIP + periodo, mista ($\alpha=0.2$)*	0.346	0.35	0.368

* α scelto post hoc (§7.4).



Barre d'errore: errore standard approssimato ($\text{std tra utenti} / \sqrt{50}$). * α scelto post hoc sugli stessi utenti.

Lettura.

- **RQ1.** Random è a 0.049, in linea con l'atteso teorico $100/2000 = 0.050$. Le baseline di popolarità restano vicine al caso (0.061 e 0.040): la popolarità non spiega i risultati. Il TF-IDF è circa **12 volte** sopra il random.
- **Deviazione standard tra utenti:** ≈ 0.21 (TF-IDF con periodo), ≈ 0.24 – 0.26 (TF-IDF senza periodo, CLIP con periodo, solo periodo), ≈ 0.17 (CLIP puro). Le medie nascondono profili molto diversi: per questo servono i test appaiati del §7.5.

7.2 RQ2: l'ablation sul periodo

Configurazione	Senza periodo	Con periodo (0.15)	Solo periodo
TF-IDF	0.432	0.588	0.354
CLIP mista ($\alpha=0.5$)	0.164	0.302	0.354

1. Il **solo periodo**, funzione identica a quella del ground truth, dà già $P@10 = 0.354$ ($\approx 7\times$ il caso). Non è un risultato "di raccomandazione", è la porzione di ground truth che i modelli conoscono in anticipo.
2. Anche **senza periodo** il TF-IDF (0.432) è sopra il caso di ~ 9 volte: il contenuto testuale porta segnale reale.
3. Aggiungere un boost di peso 0.15 porta il TF-IDF da 0.432 a 0.588 (+0.156). Quindi **0.588 è un limite superiore ottimistico** del contributo del solo contenuto; il numero più difendibile per il contenuto è 0.432, da leggere accanto a 0.354.
4. Il **vantaggio del solo contenuto TF-IDF sul solo periodo non è dimostrato**: +0.078, IC 95% $[-0.012, +0.170]$, $p = 0.134$.
5. Per CLIP, il segnale proprio senza periodo è debole: 0.164, circa $3.3\times$ il caso e circa il **38%** del TF-IDF senza periodo.

7.3 RQ3: testo contro immagine in CLIP


Con periodo ($w_p = 0.15$): testo 0.314, mista 0.302, immagine 0.252. Senza periodo ($w_p = 0$): testo 0.158, mista 0.164, immagine 0.150.

- Testo – immagine a $w_p = 0.15$: +0.062, IC $[-0.012, +0.136]$, **p = 0.106**.
- Testo – immagine a $w_p = 0$: +0.008, IC $[-0.060, +0.076]$, **p = 0.732**.

L'ordine testo > mista > immagine visto con il periodo **sparisce quasi del tutto** isolandolo (range 0.014). Con 50 utenti *non si può affermare che una modalità porti più segnale semantico dell'altra*, né che siano equivalenti: il test non ha potenza per distinguerle. Dalla semi-ampiezza degli IC bootstrap sulle differenze (≈ 0.07 – 0.09 , cioè un errore standard di ≈ 0.04) si stima, in modo approssimativo, che con 50 utenti siano rilevabili con potenza dell'80% solo differenze dell'ordine di 0.10–0.13 di P@10: differenze più piccole, come quelle tra le modalità di CLIP (0.008–0.062), restano al di sotto della sensibilità dell'esperimento.

7.4 RQ4: robustezza


Ablation su α (CLIP, $w_p = 0.15$, $k = 10$).



Il massimo in campione è a $\alpha = 0.2$ (0.346), sopra $\alpha = 0$ (0.314) e $\alpha = 0.5$ (0.302). La curva non è monotona (piccoli rimbalzi a 0.6 e a 0.8, verosimilmente rumore). Con questo α il divario dal solo periodo scende a 0.008 (0.346 contro 0.354; $p = 0.607$).

Verifica fuori campione dell' $\alpha = 0.2$ (10 seed, mai usati per sceglierlo).

	TF-IDF	CLIP $\alpha = 0.5$	CLIP $\alpha = 0.2$	Solo periodo
Media su seed 100–109	0.555	0.278	0.288	non misurato
Deviazione standard	0.028	0.027	0.028	–
Intervallo [min, max]	[0.524, 0.600]	[0.236, 0.322]	[0.246, 0.322]	–
Valore a seed 42	0.588	0.302	0.346	0.354




- Il vantaggio di $\alpha = 0.2$ su $\alpha = 0.5$ si replica ma si riduce a circa **un quarto**: +0.011 (IC bootstrap [+0.004, +0.020]) contro +0.044 in campione. Migliore in 7 seed, pari in 2, peggiore in 1. È la firma tipica della **selezione post hoc** (*winner's curse*). Il calcolo su 10 punti è stato eseguito ad hoc e non da uno script del repository.
- Il TF-IDF resta sopra CLIP $\alpha = 0.2$ in **10 seed su 10** (minimo +0.214, media +0.267; p esatto dei segni ≈ 0.002).
- I valori a seed 42 sono *un po' ottimistici* per tutti i modelli (TF-IDF 0.588 contro media 0.555): si riportano sempre anche le medie su 10 seed. L'**ordinamento** dei modelli è invece robusto.

Ablation su k.

Modello	k = 5	k = 10	k = 20	k = 50
TF-IDF + periodo	0.604	0.588	0.544	0.520
Solo periodo	0.320	0.354	0.340	0.310
CLIP mista ($\alpha = 0.5$)	0.328	0.302	0.278	0.220

(Precision@k.)




L'ordine TF-IDF > {solo periodo, CLIP} vale a ogni k. Tra solo periodo e CLIP il quadro è meno stabile: a k = 5 CLIP (0.328) supera di poco il solo periodo (0.320); da k = 10 in poi accade il contrario, con margine crescente (0.052, 0.062, 0.090). Il confronto va quindi sempre riportato **specificando k**.

7.5 Test di significatività appaiati

Wilcoxon signed-rank appaiato e IC bootstrap 95% sulla differenza media di P@10 (A – B), 50 utenti, seed 42.

#	Confronto (A contro B)	Δ medio	IC 95%	p	Esito
1	CLIP testo (α=0) contro CLIP immagine (α=1), $w_p = 0.15$	+0.062	[-0.012, +0.136]	0.106	n.s.
2	CLIP testo contro CLIP immagine, $w_p = 0$	+0.008	[-0.060, +0.076]	0.732	n.s.
3	CLIP α=0.5 senza periodo contro con periodo	-0.138	[-0.198, -0.078]	$1.3 \cdot 10^{-4}$	sig.
4	CLIP α=0.5 con periodo contro solo periodo	-0.052	[-0.134, +0.032]	0.133	n.s.
5	TF-IDF senza periodo contro solo periodo	+0.078	[-0.012, +0.170]	0.134	n.s.
6	TF-IDF con periodo contro solo periodo	+0.234	[+0.144, +0.322]	$3.3 \cdot 10^{-5}$	sig.
7	TF-IDF senza periodo contro CLIP α=0.5 senza periodo	+0.268	[+0.190, +0.346]	$6.9 \cdot 10^{-7}$	sig.
8	TF-IDF con periodo contro CLIP α=0.5 con periodo	+0.286	[+0.202, +0.370]	$1.9 \cdot 10^{-6}$	sig.
9 †	CLIP α=0.2 contro solo periodo	-0.008	[-0.082, +0.066]	0.607	n.s.
10 †	CLIP α=0.2 contro CLIP α=0.5	+0.044	[+0.006, +0.080]	0.040	al limite
11 †	TF-IDF con periodo contro CLIP α=0.2	+0.242	[+0.158, +0.326]	$1.8 \cdot 10^{-5}$	sig.

† confronti esplorativi: α = 0.2 è stato scelto sugli stessi utenti tra 11 valori, quindi i p-value sono ottimistici.



† confronti esplorativi: α=0.2 scelto post hoc sugli stessi 50 utenti. Wilcoxon signed-rank appaiato, 10.000 resample bootstrap.

Confronti multipli. Applicando, a titolo indicativo, la soglia di Bonferroni sugli 11 test ($0.05/11 \approx 0.0045$), restano significativi i confronti **3, 6, 7, 8, 11**; il confronto 10 ($p = 0.040$) **non** la supera. I risultati robusti sono quindi: il periodo aiuta CLIP (3), il TF-IDF con periodo batte il solo periodo (6), il TF-IDF batte CLIP con e senza periodo (7, 8, 11).

8. Spiegabilità

La spiegabilità è una proprietà tipica dei recommender content-based e può aumentare trasparenza e fiducia dell'utente [25]. Il modulo `src/explain.py` risponde a RQ5 con tre componenti:

- **TF-IDF: decomposizione esatta del coseno.** Poiché $\cos(q, d) = \sum_t \frac{q_t d_t}{\|q\| \|d\|}$, il punteggio si scompone in contributi per token e, aggregando i prefissi, per categoria (`nat::`, `cls::`, `tag::`). Le funzioni sono richiamate da `recommender_baseline.py`, non reimplementate: i numeri coincidono con quelli del recommender.
- **CLIP: attribuzione *leave-one-out* per preferenza.** Si rimuove una preferenza dal prompt e si misura la variazione del punteggio. Un embedding di frase non è scomponibile linearmente: questa è un'approssimazione (*proxy*) dichiarata come tale, non una decomposizione esatta.
- **Confronto α = 0 / α = 1** per singola opera, con l'avvertenza di non generalizzare da 1–2 esempi.

Tre esempi commentati (utenti 0, 1, 2) sono in `results/explanations.md`.

8.1 Diagnostica su tutti i 50 utenti: il gap sulla nazionalità

Sui tre esempi il contributo `nat` risultava sempre 0.000. La diagnostica su tutti i profili (`--diagnostics`) misura in quanti casi l'opera al primo posto del TF-IDF condivide **almeno un token** con il profilo, per categoria.

Categoria	Peso nel ground truth	Utenti con match nel top-1
Tag	0.40	96% (48/50)
Classificazione	0.15	92% (46/50)
Nazionalità	0.25	64% (32/50)

Test di McNemar (proporzioni appaiate, correzione di continuità): nazionalità contro tag $p = 0.0008$, nazionalità contro classificazione $p = 0.002$; classificazione contro tag $p = 0.68$ (indistinguibili).

NOTA

Cosa significa. La nazionalità pesa 0.25 nel ground truth, più della classificazione (0.15), ma influenza il ranking TF-IDF molto meno di quanto il suo peso dichiarato farebbe pensare. Il fatto è misurato; le due spiegazioni strutturali proposte al §9.2 sono **ipotesi non ancora verificate**.

9. Analisi critica e minacce alla validità

9.1 Osservato contro dimostrato

Affermazione	Stato	Evidenza
Tutti i modelli sono sopra il random	Osservato con ampio margine (nessun test formale contro il random)	§7.1
TF-IDF > CLIP, con e senza periodo	Supportato (a seed 42 con e senza periodo; sui 10 seed solo con periodo)	confronti 7, 8, 11; 10 seed su 10 con $w = 0.15$
TF-IDF con periodo > solo periodo	Supportato	confronto 6
TF-IDF senza periodo > solo periodo	Non dimostrato	confronto 5, $p = 0.134$
CLIP mista < solo periodo	Non dimostrato	confronto 4, $p = 0.133$
Il periodo migliora CLIP (0.164 → 0.302)	Supportato , ma dice qualcosa sul periodo, non su CLIP	confronto 3
Testo > immagine in CLIP	Non dimostrato ; nessuna differenza rilevabile	confronti 1, 2
$\alpha = 0.2$ migliore di $\alpha = 0.5$	Debole : effetto piccolo (+0.011 fuori campione)	confronto 10 e §7.4
CLIP "aggiunge valore" oltre TF-IDF o oltre il periodo	Non stabilito	–

Due correzioni rispetto a letture intermedie, entrambe emerse dai test e non da ipotesi: (i) il mix CLIP + periodo peggiore del solo periodo *non* è un risultato; (ii) l'idea che il solo contenuto TF-IDF batta il solo periodo *non* è dimostrata a 50 utenti.

9.2 Output errati e ipotesi

Osservazione	Ipotesi (non verificate)	Come testarle
Nazionalità nel top-1 TF-IDF solo nel 64% dei casi	(a) <code>classification</code> ha 6 valori molto sbilanciati (~85% <i>Paintings</i>): match frequenti per pura base rate. (b) I tag sono 527 e ciascun utente ne ha 3-5, contro 1-2 nazionalità: più tentativi di match; il coseno è dominato dall'IDF alto dei tag rari.	Correlare match e IDF dei token; ripetere la diagnostica con pesi IDF neutralizzati
CLIP puro debole (0.164, ~38% del TF-IDF senza periodo)	(a) Prompt eterogenei: il ground truth è <i>additivo</i> , ma un solo embedding media concetti scollegati. (b) La nazionalità è assente dal testo delle opere (§9.3, asimmetria informativa). (c) Modello generico su un dominio artistico. (d) Troncamento a 77 token.	Prompt per preferenza; nazionalità in <code>item_text</code> ; varianti più grandi di CLIP
Deviazione standard alta tra utenti (≈ 0.24)	Alcuni profili sono strutturalmente difficili (es. tag rari o combinazioni poco rappresentate).	Analisi degli errori per utente, non ancora fatta

9.3 Minacce alla validità

#	Minaccia	Effetto	Stato
1	Circolarità: ground truth e recommender condividono dimensioni e il termine periodo	gonfia i punteggi, soprattutto del TF-IDF	quantificata con l'ablation sul periodo (§7.2); non eliminabile con profili sintetici
2	Profili sintetici: nessun utente reale	non si sa se le preferenze simulate riflettano quelle reali	dichiarato; sviluppo futuro: studio con utenti
3	Asimmetria informativa: il TF-IDF ha token di nazionalità, il testo CLIP no (solo nome artista), pur essendo nel prompt	parte del divario TF-IDF/CLIP potrebbe derivare da qui	non testata
4	Scale diverse: coseno TF-IDF grezzo contro punteggi CLIP min-max, con lo stesso peso nominale 0.15	l'influenza effettiva del periodo differisce tra i due modelli	mitigata con $w = 0/w_p = 0$ a confronto diretto
5	Selezione post hoc di α sugli stessi utenti	p-value ottimistici	verificata fuori campione (§7.4)
6	Un solo campione di 50 utenti a seed 42	valori assoluti ottimistici	10 seed; "solo periodo" sui 10 seed non ancora misurato
7	Dominio singolo: 2000 dipinti con immagine pubblica	generalizzabilità limitata; il campione non è casuale	dichiarato
8	Un solo modello CLIP (ViT-B/32)	l'esito potrebbe cambiare con modelli più grandi o affinati	non testato
9	Gain binario e relevance set fisso a 100	perde la graduazione dell'affinità	il punteggio continuo esiste: NDCG graduato è un'estensione
10	Nessuna metrica beyond-accuracy , nessuna valutazione online	non si sa nulla su novità, diversità, serendipità	sviluppo futuro
11	Recall con tetto 0.10	va sempre normalizzata o accompagnata dalla precision	gestita (§2.6)

10. Sviluppi futuri

Priorità alta (chiudono limiti dichiarati)

1. **Nazionalità in `item_text`** e rigenerazione degli embedding di testo: testa la minaccia 3.
2. **Solo periodo sui 10 seed** (`ablation_study.py --seed_sweep --skip_clip --period_weight 1.0`): estende la robustezza all'unico confronto centrale ancora a seed 42.
3. **Analisi degli errori per utente**: quali profili falliscono e perché (§9.2).

Modelli 4. **Prompt per preferenza** anziché un prompt unico: un embedding per nazionalità, classificazione e tag, con aggregazione dei punteggi min-max, più coerente con il ground truth additivo. 5. **Recommender ibrido TF-IDF + CLIP** a livello di punteggio, con peso β da variare: unisce il segnale lessicale con quello semantico. 6. **Esperimento "metadati mancanti"**: togliere i tag a una frazione di opere lato recommender lasciando invariato il ground truth. Il TF-IDF perde segnale, CLIP-immagine no: è lo scenario di *cold-start di item* in cui CLIP dovrebbe mostrare valore. Collegato alla generazione automatica di tag (§2.4).

Valutazione 7. **NDCG con gain graduato** dal punteggio continuo di affinità. 8. **Metriche beyond-accuracy** (copertura del catalogo, novità, diversità, serendipità) e **diversificazione** con MMR [23]: rilevanti per portare all'utente opere della coda lunga. 9. **Design alternativo dei profili** e forma alternativa del boost temporale. 10. **Studio con utenti reali** e, se un museo disponesse di log di visita, **CF item-based** o ibrido (§2.1). 11. **Diagnostica di allineamento testo-immagine di CLIP** sul catalogo (similarità della stessa opera contro opere diverse; quota di opere la cui immagine è il miglior match testuale di sé stessa): spiegherebbe quanto bene il modello generico riconosce il dominio dei dipinti europei, ed è coerente con la minaccia 8 del §9.3.

11. Conclusioni

Il lavoro ha confrontato in modo controllato un recommender lessicale (TF-IDF) e uno semantico multimodale (CLIP) per il patrimonio culturale, in assenza di dati di interazione.

Risposte alle domande di ricerca.

- **RQ1.** Sì: tutti i modelli personalizzati sono nettamente sopra random e popolarità (TF-IDF $\approx 12\times$ il caso).
- **RQ2.** Il termine periodo pesa molto: da solo dà 0.354, e senza di esso il TF-IDF scende da 0.588 a 0.432. Il vantaggio del *solo contenuto* sul *solo periodo* non è statisticamente dimostrato ($p = 0.134$).
- **RQ3.** CLIP è significativamente sotto il TF-IDF ($p < 0.0001$ a seed 42; con il periodo attivo, 10 seed su 10). Testo e immagine non sono distinguibili.
- **RQ4.** L'ordinamento dei modelli è robusto a k e ai seed; i valori assoluti a seed 42 sono un po' ottimistici e il α "migliore" è in gran parte un effetto di selezione.
- **RQ5.** La scomposizione del coseno ha mostrato che la nazionalità guida il ranking molto meno di quanto il suo peso nel ground truth suggerirebbe (64% contro 92–96%).

Contributo metodologico. Il valore del lavoro sta tanto nei numeri quanto nel modo di leggerli: la distinzione costante tra differenza *osservata* e differenza *dimostrata*, la quantificazione del confondente prima di attribuire un merito ai modelli, e la verifica fuori campione di una scelta fatta sui dati. Il divario TF-IDF/CLIP è atteso,

perché il ground truth è costruito sui metadati che il TF-IDF usa direttamente, ma resta da capire quanto dipenda da fattori controllabili (nazionalità assente dal testo CLIP, prompt eterogenei): sono i primi esperimenti proposti al §10.

12. Bibliografia

1. Radford, A., Kim, J. W., Hallacy, C., et al. (2021). *Learning Transferable Visual Models From Natural Language Supervision*. ICML 2021. [arXiv:2103.00020](https://arxiv.org/abs/2103.00020). Modello: <https://huggingface.co/openai/clip-vit-base-patch32>
2. Jannach, D., Zanker, M., Felfernig, A., & Friedrich, G. (2010). *Recommender Systems: An Introduction*. Cambridge University Press.
3. Croft, W. B., Metzler, D., & Strohman, T. (2010). *Search Engines: Information Retrieval in Practice*. Addison-Wesley.
4. Salton, G., Wong, A., & Yang, C. S. (1975). A vector space model for automatic indexing. *Communications of the ACM*, 18(11), 613–620.
5. Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21.
6. Resnick, P., Iacovou, N., Suchak, M., Bergstrom, P., & Riedl, J. (1994). GroupLens: An open architecture for collaborative filtering of netnews. *CSCW '94*.
7. Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. *WWW '01*.
8. Linden, G., Smith, B., & York, J. (2003). Amazon.com recommendations: Item-to-item collaborative filtering. *IEEE Internet Computing*, 7(1), 76–80.
9. Anderson, C. (2004). The Long Tail. *Wired*, 12(10).
10. Schein, A. I., Popescul, A., Ungar, L. H., & Pennock, D. M. (2002). Methods and metrics for cold-start recommendations. *SIGIR '02*.
11. Herlocker, J. L., Konstan, J. A., Terveen, L. G., & Riedl, J. T. (2004). Evaluating collaborative filtering recommender systems. *ACM TOIS*, 22(1), 5–53.
12. Cremonesi, P., Koren, Y., & Turrin, R. (2010). Performance of recommender algorithms on top-N recommendation tasks. *RecSys '10*.
13. Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM TOIS*, 20(4), 422–446.
14. Xu, Z., Fu, Y., Mao, J., & Su, D. (2006). Towards the semantic web: Collaborative tag suggestions. *Collaborative Web Tagging Workshop, WWW 2006*.
15. Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.
16. Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
17. McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157.
18. The Metropolitan Museum of Art. *Open Access e Collection API* (licenza CCO). <https://metmuseum.github.io/>
19. Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *NeurIPS 32*.

20. Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *EMNLP 2020, System Demonstrations*.
21. Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
22. Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.
23. Carbonell, J., & Goldstein, J. (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. *SIGIR '98*.
24. Sansonetti, G., Gasparetti, F., Micarelli, A., Cena, F., & Gena, C. (2019). Enhancing cultural recommendations through social and linked open data. *User Modeling and User-Adapted Interaction*, 29(1), 121–159. DOI: 10.1007/s11257-019-09225-8.
25. Tintarev, N., & Masthoff, J. (2015). Explaining recommendations: Design and evaluation. In *Recommender Systems Handbook* (2nd ed., pp. 353–382). Springer.
26. Smucker, M. D., Allan, J., & Carterette, B. (2007). A comparison of statistical significance tests for information retrieval evaluation. *CIKM '07*, 623–632.
27. Dunn, O. J. (1961). Multiple comparisons among means. *Journal of the American Statistical Association*, 56(293), 52–64.

Appendice A — Provenienza dei numeri

Risultato	File in results/
Random e popolarità	random_baseline_metrics.json
TF-IDF ($w = 0.15, 0, 1$)	baseline_metrics.json, baseline_metrics_pw0.json, baseline_metrics_pw1.json
CLIP ($\alpha = 0, 0.5, 1$; $w_p = 0.15$)	clip_metrics.json, clip_recommendations.json
Ablation periodo CLIP	clip_metrics_pw0.json, clip_metrics_pw1.json, clip_metrics_pw0_extremes.json
Sweep α (0.0–1.0)	clip_alpha_sweep.json
Sweep k	ablation_k.json
Seed-sweep TF-IDF / CLIP $\alpha = 0.5$ / CLIP $\alpha = 0.2$	ablation_seed.json, ablation_seed_clip.json, ablation_seed_clip_alpha02.json
11 test di significatività	significance_tests.json
Spiegabilità e diagnostica nazionalità	explanations.md, tfidf_diagnostics.json

► Comandi delle ablation

Le figure di questo report sono generate dai valori riportati nelle tabelle (figures/).